STAT.DATATHON 2026 · Финальная защита · Трек «AI for Official Statistics»

ИИ-контроль качества анкет бюджетов домохозяйств (Д-004)

Программа сама находит подозрительные анкеты, объясняет интервьюеру, что в них не так, и становится точнее с каждой проверкой.

Команда «DataX»
Тариелова Алия Тариеловна
Ырысбеков Жаныбек Ырысбекович
Рахимбекова Салия Элнуровна
Джанболотов Кубат

Все примеры — из синтетических (учебных) данных Бюро национальной статистики за 2024 год. Код: github.com/closer312/d004-quality-ai

Проблема: ошибки в анкетах ищут вручную

- Анкету Д-004 каждый квартал заполняют **12 000 семей**. Только за 2024 год в ней **1 720 367** записей о покупках.
- При вводе бывают ошибки: лишний ноль, сумма в тысячах вместо тенге, доход не в той графе, раздел введён дважды.
- Из-за них неверно считаются средние доходы и расходы семей, а значит, и уровень бедности.
- По Инструкции к Д-004 (п. 9) интервьюер перепроверяет анкету и при сомнениях снова звонит семье. Но проверить всё невозможно.

Наши три вопроса

1. Можно ли найти большинство ошибок, проверив лишь малую часть анкет?
2. Сколько работы это экономит?
3. Может ли программа учиться на ответах интервьюеров?

Ответы — на последнем слайде.

Это совпадает с планом Бюро: ИИ-помощник «Контроль качества первичных данных» (2027).

Данные

48 000
анкет за 2024 год (семья × квартал)

97 862
записей о доходах

1 720 367
записей о покупках

20
регионов, город и село

Что используем

- Анкету Д-004: расходы, займы, доходы, своё хозяйство.
- Анкету Д-008: кто живёт в семье и сколько им лет.
- Справочник товаров (550 позиций) и Инструкцию к Д-004.

Важно знать

- Данные учебные: связи между разделами анкеты в них слабее, чем в жизни.
- Где настоящие ошибки, никто не знает. Поэтому мы сами добавили ошибки и проверили, найдёт ли их программа.

Как работает

Берём анкету семьи: доходы, расходы, долги, состав семьи

↓

Правила — 24
проверки по бланку и Инструкции: например, пенсия у 25-летнего, доход у ребёнка, расходы без денег на них

Проверка каждой покупки
сравниваем цену с обычной для этого товара; проверяем, не лишний ли ноль

Модели машинного обучения
ищут необычные анкеты и расходы, которые не похожи на расходы похожих семей

↓

Явные ошибки исправляются сами, по Инструкции: 14,1% анкет, звонить не нужно

Остальные получают оценку риска от 0 до 100 и объяснение: 16,0% анкет

↓

Интервьюер проверяет анкеты по порядку, от самых подозрительных

Его ответы помогают программе лучше выбирать анкеты в следующем квартале

Что видит интервьюер

Домохозяйство 2024001784 · 1 кв. 2024 · Жетiсу, город **риск 94/100**

- правило + ИИ-модель Расходы 8 637 314 тг: в 28 раз больше дохода семьи (311 696 тг) и примерно в 43 раза больше, чем обычно у похожих семей (около 200 тыс. тг). Кредиты, долги и сбережения не указаны. Крупнейшая запись — «Набор мягкой мебели» на 8 300 000 тг.

Что уточнить у респондента:

- Уточните, на какие деньги сделаны крупные покупки (кредит, сбережения, помощь родственников), и сверьте их суммы с бумажной анкетой.

- Вместо кода ошибки — **понятная фраза** с цифрами из анкеты.
- Рядом — **что спросить у семьи**.
- Метка показывает, кто нашёл: правило, проверка покупки или модель.
- Решает всегда человек. Сама программа исправляет только явные ошибки по Инструкции.

Насколько хорошо находит ошибки



63%
ошибок найдено, если проверить 2% анкет

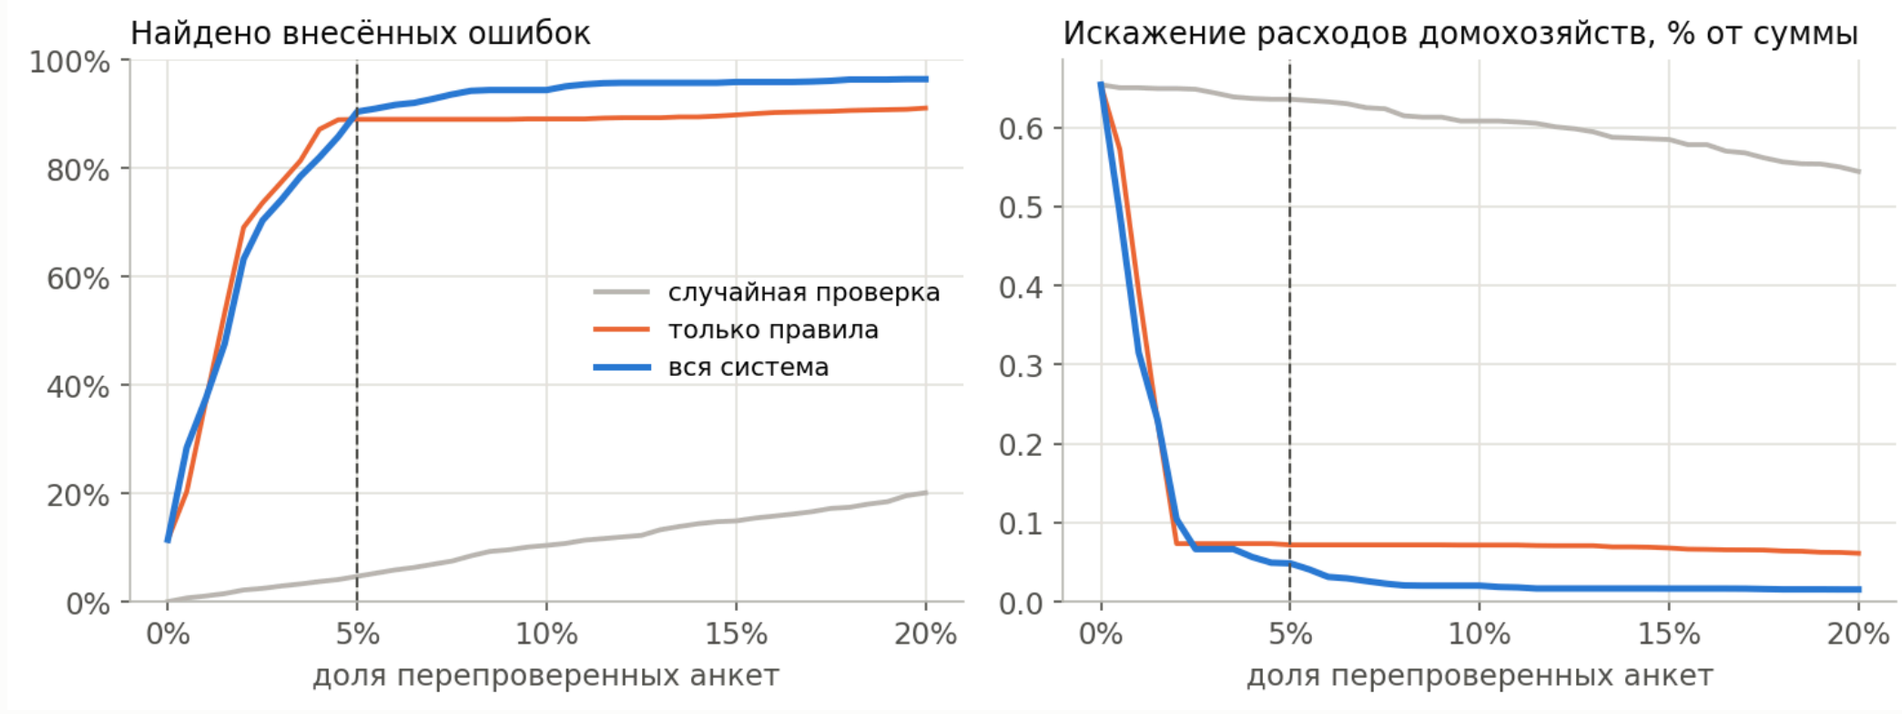
90%
если проверить 5% анкет (наугад — нашли бы 5%)

73%
самых подозрительных анкет действительно с ошибкой

- 8 видов ошибок из 9 находятся полностью.
- Труднее всего — лишний ноль в одной мелкой покупке. Если он сильно меняет расходы семьи, находится 78% таких ошибок при проверке 10% анкет.

Мы добавили в анкеты 9 видов ошибок, по 150 каждого (1 350 анкет), и повторили опыт 3 раза.

Сколько времени экономит

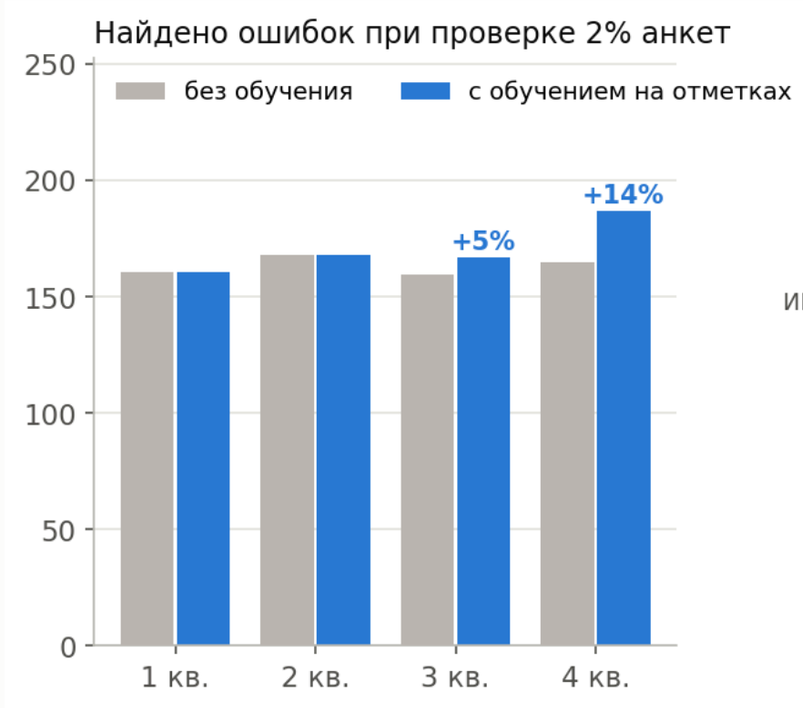


Как выбирать анкеты	Сколько проверить, чтобы найти 90% ошибок	Часов работы*
наугад	43 200	14 400
только по правилам	7 440	2 480
наша программа	**2 400**	**800**

- Звонков семьям в **18 раз** меньше, чем при проверке наугад.
- Ошибка в общей сумме расходов: было 0,65%, стало 0,05%. Ошибки в доходах исчезают полностью.

* считаем 20 минут на один звонок.

Программа учится на ответах интервьюеров





- Интервьюер отмечает: «ошибка подтвердилась» или «всё верно».
- Когда наберётся 400 отметок, программа учится на них и в следующем квартале выбирает анкеты точнее.

- При проверке 2% анкет ошибок находится больше: **+5%** в 3 квартале и **+14%** в 4.
- Справа видно, каким сигналам можно доверять больше.

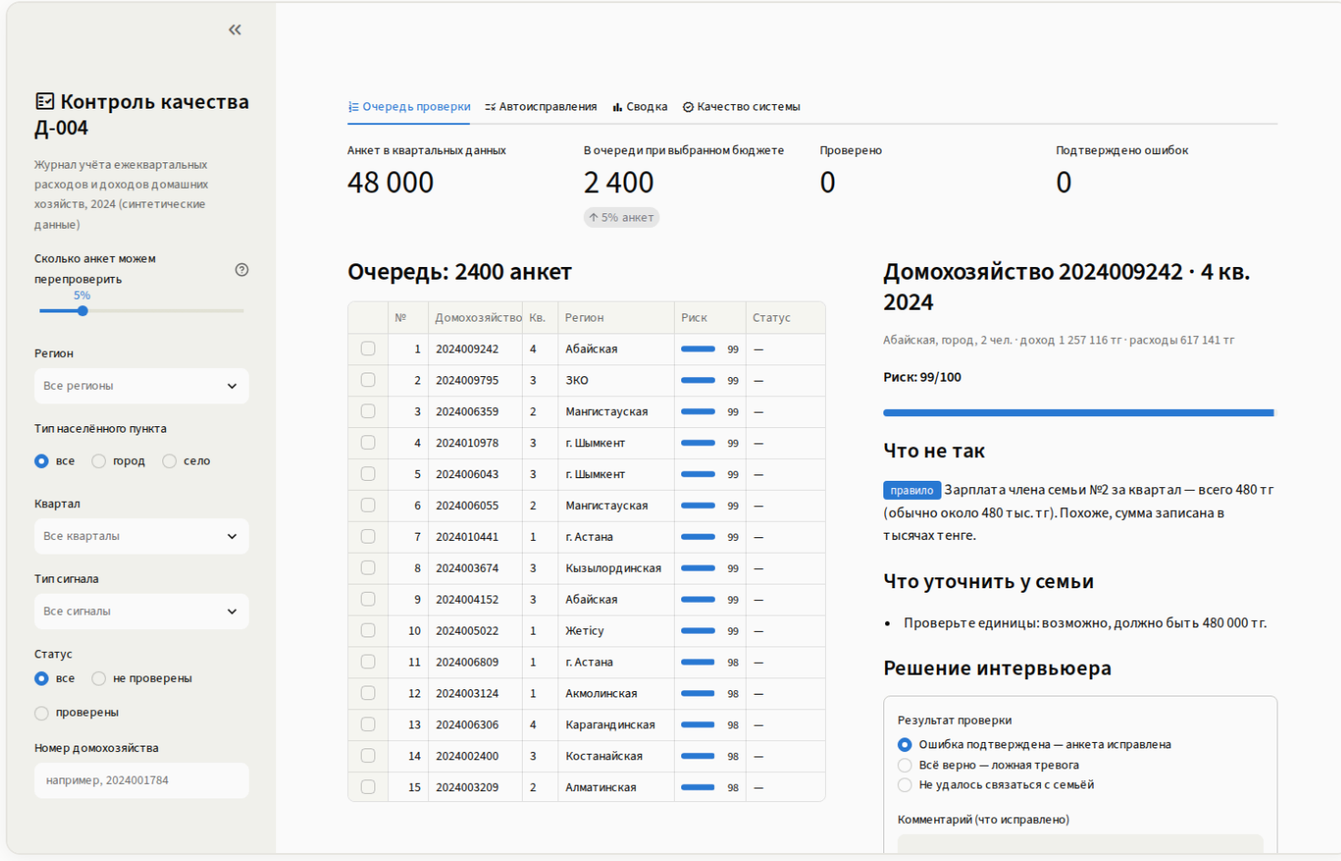
Это расчёт на учебных данных. На настоящих отметках цифры будут другими.

Проверки по Инструкции к Д-004

Что проверяем	Пункт Инструкции	Что делает программа	Доля анкет
Ответы на вопросы, которые надо было пропустить	п. 8	исправляет сама	8,7%
Семья продала урожай или продукцию хозяйства, но этих денег нет в доходах	п. 7	исправляет сама	5,0%
Доход от продажи урожая больше, чем весь доход от своего дела	логика анкеты	исправляет сама	2,2%
Доход от продажи урожая есть, а самих продаж в анкете нет	п. 7	спрашивает интервьюера	1,5%
Доход записан у ребёнка младше 15 лет	п. 7	спрашивает интервьюера	0,2%
Сумма не в целых тенге или код не из справочника	п. 5	спрашивает интервьюера	0,1%

Каждое исправление записывается в журнал. Срабатываний по продажам много из-за особенностей учебных данных.

Рабочее место интервьюера



- **Список анкет** — от самых подозрительных. Можно выбрать, сколько анкет проверять, регион и квартал.
- **Карточка анкеты:** что не так и что спросить у семьи.
- **Кнопка «Сохранить»** — ответ интервьюера идёт в обучение.
- Отдельно: журнал автоисправлений, сводка по регионам, качество программы.

Ответы на наши вопросы

1. **Можно ли найти большинство ошибок, проверив малую часть анкет?** Да: проверка 5% анкет с самым высоким риском находит 90% ошибок.
2. **Сколько работы это экономит?** Звонков семьям в 18 раз меньше, чем при проверке наугад.
3. **Может ли программа учиться?** Да: после 400 отметок интервьюеров она находит до +14% ошибок.

90%
ошибок находится при проверке всего 5% анкет

в 18 раз
меньше звонков семьям, чем при проверке наугад

14,1%
анкет исправлены сами по Инструкции

+14%
ошибок находится больше после обучения на ответах

Программа не заменяет интервьюера. Она подсказывает, куда смотреть, объясняет почему и учится на его решениях.