STAT.DATATHON 2026 · Результат 2 · Трек «AI for Official Statistics» · 07.10.2026

ИИ-контроль качества анкет бюджетов домохозяйств (Д-004)

Команда «DataX» · Тариелова Алия Тариеловна, Ырысбеков Жаныбек Ырысбекович, Рахимбекова Салия Элнуровна, Джанболотов Кубат

Проблема

- Анкета Д-004: 12 000 семей × 4 квартала, 12 таблиц, **1 720 367** записей о покупках только за 2024 год.
- Ошибки ввода — лишний ноль, сумма в тысячах вместо тенге, не та графа, двойной ввод — искажают оценки доходов, расходов и бедности.
- Сейчас проверка ручная. Инструкция к Д-004, п. 9: *«интервьюер повторно просматривает форму, в случае обнаружения каких-либо несоответствий, вновь обращается в домашнее хозяйство... и выясняет недостающую информацию»*. Наша система автоматизирует именно этот шаг.
- В плане ИИ-ассистентов Бюро: «Контроль качества первичных данных» (2027) и «Обратная связь по качеству отчёта» (2028).

Решение

Система **ранжирует анкеты по риску ошибки** и **объясняет интервьюеру простым языком**, что перепроверить. Решение остаётся за специалистом.

Гипотезы

1. **H1.** Логические правила надёжно находят известные типы ошибок.
2. **H2.** Статистические выбросы и ML-модели находят то, что правила не описывают: нетипичные суммы и редкие сочетания ответов.
3. **H3.** Проверка 5% анкет с наибольшим риском находит большую часть ошибок — во много раз эффективнее случайной проверки.

Как это работает

Анкета Д-004 (12 таблиц) + состав семьи Д-008

↓

Профиль домохозяйства: доходы, расходы, долги, состав

↓

Правила
21 логических проверок: переходы и коды бланка Д-004, сверка с Д-008, пенсия у 25-летнего, двойной ввод, долги без источника денег…

Выбросы и модель покупки
цена против 550 позиций справочника; проверка «лишнего нуля»; бустинг оценивает обычную цену покупки для этой семьи

ИИ-модели
Isolation Forest — редкие сочетания; бустинг — «ожидаемые расходы» похожих семей

↓

Однозначные нарушения бланка → **автоисправление** + журнал изменений

Остальное → **риск 0–100** и объяснение для интервьюера

↓

Специалист подтверждает или исправляет → обратная связь для настройки

Из 48 000 анкет 2024 года 9% исправлены автоматически, у 15% есть сигнал для интервьюера — проверяются по убыванию риска.

Пример объяснения (запись из синтетических данных 2024 года)

Домохозяйство 2024001784 · 1 кв. 2024 · Жетісу, город

риск 94/100

- правило + ИИ-модель Расходы 8 637 314 тг: в 28 раз больше дохода семьи (311 696 тг) и примерно в 43 раза больше, чем обычно у похожих семей (около 200 тыс. тг). Кредиты, долги и сбережения не указаны. Крупнейшая запись — «Набор мягкой мебели» на 8 300 000 тг.

Что уточнить у респондента:

- Уточните, на какие деньги сделаны крупные покупки (кредит, сбережения, помощь родственников), и сверьте их суммы с бумажной анкетой.

Первые результаты: эксперимент с внесёнными ошибками



В чистые синтетические анкеты 2024 года внесли 9 типов ошибок по 150 штук (1 350 анкет), прогнали систему и посмотрели, где они оказались в рейтинге риска. Среднее по 3 повторам.

90%

ошибок найдено при проверке 5% анкет (случайная проверка — 5%)

94%

найдено при проверке 10% анкет

73%

топ-2% по риску — действительно ошибки

- **H1 подтверждается:** правила полностью находят 8 из 9 типов ошибок; нарушения переходов бланка исправляются автоматически и не занимают очередь интервьюера.
- **H2 — частично:** выбросы находят все суммы в тысячах тенге, ИИ-модель — пропущенные разделы расходов и ещё 813 анкет, которые не описывает ни одно правило. Слабое место — «лишний ноль» в одной покупке: 12% при 5% и 50% при 10% (крупные — 42% и 77%).
- **H3 подтверждается:** топ-5% по риску в 18 раз эффективнее случайной выборки.